Trường đại học bách khoa hà nội

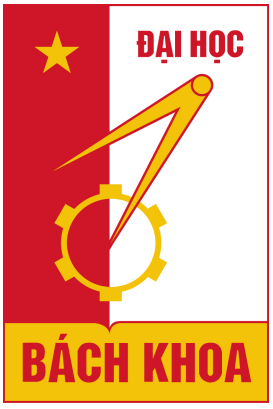

Báo cáo bài tập lớn môn học:

Lý thuyết ngôn ngữ và phương pháp dịch

TÌM HIỂU BỘ SINH TRÌNH PHÂN TÍCH TỪ VỰNG FLEX

Sinh viên thực hiện:
Tạ Quang Tùng
MSSV: 20154280

Giáo viên hướng dẫn:
TS. Phạm Đăng Hải

Hà Nội, Ngày 25 tháng 10 năm 2018

Mục lục

1 Giới thiệu về bộ sinh trình phân tích từ vựng Flex

Flex là bộ sinh chương trình phân tích từ vựng, là một phần mềm miễn phí và mã nguồn mở thay thế cho Lex. [3] Nó thường xuyên được sử dụng đi kèm với bộ sinh chương trình phân tích cú pháp Yacc (hoặc mã nguồn mở thay thế là GNU Bison) để tạo nên 2 khối chức năng cơ bản của một chương trình dịch.

Flex được viết bằng ngôn ngữ C bởi Vern Paxson vào khoảng năm 1987. Flex nhận đầu vào là một file chỉ dẫn, thông thường có đuôi là **.l**. Từ đó Flex có thể sinh ra mã C có thể biên dịch và thực thi mà không cần thêm bất kì thư viện ngoài nào.

Mã C sinh ra bởi Flex sử dụng Automata hữu hạn đơn định (Deterministic Finite Automation - DFA) để thực hiện việc tách xâu đầu vào thành các từ tố tương ứng. Thuật toán thường có độ phức tạp thời gian tính là $O(n)$ với n là độ dài xâu đầu vào.

Flex chỉ có thể sinh ra mã code C hoặc C++.

2 Cấu trúc của file chỉ dẫn trong Flex

Mỗi file chỉ dẫn đầu vào cho Flex bao gồm 3 vùng, được phân tách nhau bởi các dòng chỉ chứa xâu '%%': [2]

```
definitions
%%
rules
%%
user code
```

Trong đó:

- **definitions**: Vùng chứa các định nghĩa.
- **rules**: Vùng chứa luật của các từ tố.
- **user code**: Vùng chứa mã C/C++ được thêm vào.

2.1 Vùng định nghĩa - Definitions Section

Vùng định nghĩa chứa các định nghĩa tên và các định nghĩa điều kiện bắt đầu. Định nghĩa tên có dạng:

```
name definition
```

'name' là các tên có cú pháp giống như các tên trong ngôn ngữ C. **'definition'** là phần được lấy từ kí tự không phải kí tự trắng đầu tiên sau **'name'** và đến hết dòng. **'name'** không được thụt lề đầu dòng. Các định nghĩa có thể được tham chiếu đến bằng cách sử dụng **'{name}'** và nó sẽ được chuyển thành **'(definition)'**.
Ví dụ:

```
DIGIT [0-9]
```

Thì **'{DIGIT}'** sẽ được chuyển thành **'([0-9])'**.

Bất kì một dòng nào trong vùng này được viết thụt lề đầu dòng hoặc được bao xung quanh bởi %{ và %} thì sẽ được sao chép nguyên văn vào file mã nguồn sinh ra.
Ví dụ:

```
    int number, count;
%{
#include <math.h>
%}
```

Thì đoạn code sau sẽ được sao chép nguyên văn vào file đầu ra:

```
int number, count;
#include <math.h>
```

2.2 Vùng các luật - Rules Section

Là vùng bao gồm một chuỗi các luật có dạng:

```
pattern action
```

Trong đó, **pattern** không được phép thụt lề đầu dòng. Và phần **action** phải được bắt đầu trên cùng một dòng.

Ở trong vùng các luật, bất kì một dòng nào mà có thụt lề đầu dòng hoặc các dòng được bao bởi %{ %} nằm trước luật đầu tiên có thể được sử dụng để khai báo những biến địa phương cho hàm phân tích từ tố. Và các đoạn code này sẽ được thực thi mỗi khi hàm phân tích từ tố được gọi.

Các **pattern** là các biểu thức chính quy phiên bản mở rộng, bao gồm:

- **x**
  Nhận diện được kí tự 'x'.
- **.**
  Bất kì cứ kị tự nào ngoại trừ dấu xuống dòng.
- **[xyz]**
  Là một "Lớp các kí tự". Nhận diện được một trong các kí tự: 'x', 'y', 'z'.
- **[abj-oZ]**
  Là một "Lớp các kí tự". Nhận diện được kí tự 'a', 'b', bất kì kí tự nào trong khoảng từ 'j' đến 'o', hoặc kí tự 'Z'.
- **[^A-Z\n]**
  Là một "Lớp phủ định các kí tự". Nhận diện được bất kì kí tự nào không nằm trong khoảng được chỉ định. Ở đây, khoảng đó là các kí tự từ 'A' tới 'Z' và kí tự xuống dòng.
- **r***
  Không hay nhiều **r**. Trong đó **r** là một biểu thức chính quy bất kì.
- **r+**
  Một hay nhiều **r**. Trong đó **r** là một biểu thức chính quy bất kì.
- **r?**
  Không hay một **r**. Trong đó **r** là một biểu thức chính quy bất kì.

- **r{2, 5}**
  r được xuất hiện liên tiếp từ 2 đến 5 lần. Trong đó **r** là một biểu thức chính quy bất kì.
- **r{3.}**
  r được xuất hiện từ 3 lần trở lên. Trong đó **r** là một biểu thức chính quy bất kì.
- **r{4}**
  r được xuất hiện chính xác 4 lần. Trong đó **r** là một biểu thức chính quy bất kì.
- **{name}**
  Thay thế định nghĩa 'name' thành 'definition' đã được chỉ định ở vùng định nghĩa.
- **rs**
  Phép nối biểu thức chính quy.
- **r|s**
  Phép hợp biểu thức chính quy.
- **^r**
  Nhận diện các xâu từ **r** nhưng phải bắt đầu dòng.
- **r$**
  Nhận diện các xâu từ **r** nhưng phải kết thúc dòng.
- **(?r-s:pattern)**
  Áp dụng tùy chọn **r**, loại bỏ tùy chọn **s** lên biểu thức chính quy **pattern**. Ví dụ tùy chọn **i** để không phân biệt hoa và thường (case-insensitive).

2.3 Vùng mã nguồn bổ sung - User Code Section

Các dòng code trong vùng này đơn giản được sao chép vào file mã nguồn đầu ra. Vùng này có thể không có, có thể bỏ '%%' cuối cùng nếu vùng này trống rỗng.

3 Cách sử dụng FLex

3.1 Hoạt động của Flex

Flex sẽ phân tích file chỉ dẫn đầu vào rồi tạo một DFA tương ứng. DFA này được mã hóa trong mã nguồn C/C++. DFA này sẽ ưu tiên những **pattern** có độ dài càng lớn.

Chương trình sinh ra bởi Flex sẽ mặc định đọc dữ liệu từ **stdin**. Ta có thể sử dụng hàm **void yyrestart(FILE *file)** để thiết lập con trỏ file mà chương sẽ sử dụng để đọc file đầu vào.

Chương trình sẽ bắt đầu quá trình nhận diện xâu khi hàm **int yylex();** được gọi. Khi đó, nếu một xâu được nhận diện bởi một luận nào đó, mã nguồn C/C++ tương ứng với **pattern** được thực thi. Nếu đoạn mã đấy không có **return**, chương trình sẽ tiếp tục phân tích từ tố tiếp theo [4]. Nếu có **return**, giá trị từ tố (hay giá trị **return**) được trả về qua giá trị trả về của hàm **yylex()**. Xâu được nhận diện sẽ nằm trong biến toàn cục **yytext**, độ dài của xâu sẽ nằm trong biến toàn cục **yyleng**.

Nếu không một **pattern** nào nhận diện được xâu đầu vào, **luật mặc định** sẽ được thực thi: Kí tự tiếp theo trong file đầu vào sẽ được coi như là nhận diện được, và sẽ được in ra màn hình.

Kích thước giới hạn của **yytext** được định nghĩa bởi hằng **YYLMAX**, là một số khá lớn. Ta có thể thay đổi nó đơn giản bởi định nghĩa lại: **#define YYLMAX <number>**.

Hơn nữa, để có thể biên dịch được chương trình, ta cần phải định nghĩa hàm **yywrap**. Hàm **int yywrap()** được gọi khi đầu vào đã được đọc hết. Nếu hàm trả về giá trị 1, quá trình phân tích kết thúc, trả về 0 nếu như việc xử lý vẫn còn tiếp tục. Ta có thể thay đổi biến toàn cục **yyin** trỏ đến một file khác (hoặc sử dụng **yyrestart**) và chương trình sẽ tiếp tục phân tích từ file mới đó. [1]

Hoặc đơn giản ta có thể định nghĩa:

```
int yywrap() {
    return 1;
}
```

Trong vùng **User Code Section** của file chỉ thị.

3.2 Ví dụ một file đầu vào Flex đơn giản

3.3 Sử dụng Flex bằng dòng lệnh

Một file chỉ thị đầu vào cho Flex có đuôi thông thường là **.l**, ví dụ **scanner.l**. Để biên dịch file này sang file C/C++, ta sử dụng:

```
$ flex scanner.l
```

Mặc định lệnh trên sẽ sinh ra một file **lex.yy.c**. Ta có thể dịch file này bằng một trình dịch C thông thường, ví dụ **gcc**:

```
$ gcc lex.yy.c -o main
```

Ta có thể chỉ định tên file xuất ra bởi flex bằng cách sử dụng tùy chọn **-o <filename>**:

```
$ flex -o scanner.lex.cpp scanner.l
```

4 Sử dụng Flex để tạo bộ phân tích từ vựng cho ngôn ngữ PL/0 mở rộng

4.1 File chỉ dẫn đầu vào

scanner.l

```
%{
#include <string.h>
#include <ctype.h>

enum Token {
    TOKEN_IDENT = 1,
    TOKEN_NUMBER,

    TOKEN_BEGIN, TOKEN_CALL, TOKEN_CONST, TOKEN_DO,
    TOKEN_ELSE, TOKEN_END,
    TOKEN_FOR, TOKEN_IF, TOKEN_ODD,
    TOKEN_PROCEDURE, TOKEN_FUNCTION,
```

```
    TOKEN_PROGRAM, TOKEN_THEN, TOKEN_TO,
    TOKEN_VAR, TOKEN_WHILE,

    TOKEN_PLUS, TOKEN_MINUS, TOKEN_TIMES, TOKEN_DIVIDE, TOKEN_REMAINDER,

    TOKEN_EQ, TOKEN_NE, TOKEN_LT, TOKEN_GT, TOKEN_LE, TOKEN_GE,

    TOKEN_LPARENT, TOKEN_RPARENT,
    TOKEN_LBRACKET, TOKEN_RBRACKET,

    TOKEN_PERIOD, TOKEN_COMMA, TOKEN_SEMICOLON, TOKEN_ASSIGN,
};

#define IDENT_NAME_SIZE 10
#define MAX_DIGIT_COUNT 9

%}

DIGIT       [0-9]
ALPHA       [A-Za-z]
ALPHADIGIT  [A-Za-z0-9]
WHITESPACE  [ \n\t\r]

%%

(?i:begin)              return TOKEN_BEGIN;
(?i:call)               return TOKEN_CALL;
(?i:const)              return TOKEN_CONST;
(?i:do)                 return TOKEN_DO;
(?i:else)               return TOKEN_ELSE;
(?i:end)                return TOKEN_END;

(?i:for)                return TOKEN_FOR;
(?i:if)                 return TOKEN_IF;
(?i:odd)                return TOKEN_ODD;
(?i:procedure)          return TOKEN_PROCEDURE;
(?i:function)           return TOKEN_FUNCTION;
(?i:program)            return TOKEN_PROGRAM;
(?i:then)               return TOKEN_THEN;
(?i:to)                 return TOKEN_TO;
(?i:var)                return TOKEN_VAR;
(?i:while)              return TOKEN_WHILE;

"+"                     return TOKEN_PLUS;
"-"                     return TOKEN_MINUS;
"*"                     return TOKEN_TIMES;
"/"                     return TOKEN_DIVIDE;
"%"                     return TOKEN_REMAINDER;

"="                     return TOKEN_EQ;
"<>"                    return TOKEN_NE;
"<"                     return TOKEN_LT;
">"                     return TOKEN_GT;
"<="                    return TOKEN_LE;
">="                    return TOKEN_GE;
```

```
"("                     return TOKEN_LPARENT;
")"                     return TOKEN_RPARENT;
"["                     return TOKEN_LBRACKET;
"]"                     return TOKEN_RBRACKET;

"."                     return TOKEN_PERIOD;
","                     return TOKEN_COMMA;
";"                     return TOKEN_SEMICOLON;
":="                    return TOKEN_ASSIGN;


{ALPHA}{ALPHADIGIT}*    return TOKEN_IDENT;
{DIGIT}+                return TOKEN_NUMBER;
{WHITESPACE}            ;
. {
    printf("Khong nhan dien duoc ki tu: %s\n", yytext);
    exit(-1);
}

%%

int yywrap() {
    return 1;
}

int main(int argc, char **argv) {
    if (argc <= 1) {
        printf("Thieu ten file\n");
        return -1;
    }

    FILE *file = fopen(argv[1], "rb");
    if (file == NULL) {
        printf("Khong the doc file %s\n", argv[1]);
        return -1;
    }
    yyrestart(file);

    int token;
    while (token = yylex()) {
        if (token == TOKEN_IDENT) {
            char str[256];
            // Lay xau con cua xau yytext
            strncpy(str, yytext, IDENT_NAME_SIZE);
            str[IDENT_NAME_SIZE] = '\0';
            printf("Token: %s\n", str);
        }
        else if (token == TOKEN_NUMBER) {
            int i = 0;
            for (; i < yyleng; i++)
                if (yytext[i] != '0')
                    break;
            if (yyleng - i > MAX_DIGIT_COUNT) {
                printf("So vuot qua 9 chu so!!\n");
                exit(-1);
            }
```

```
            int num = atoi(yytext + i);
            printf("Number: %d\n", num);
        }
        else {
            for (int i = 0; i < yyleng; i++)
                yytext[i] = tolower(yytext[i]);
            printf("%s\n", yytext);
        }
    }

    fclose(file);
    return 0;
}
```

4.2 Chạy thử nghiệm

Biên dịch:

```
$ flex scanner.l
$ gcc lex.yy.c -o main
```

File **input** đầu vào:

```
tungtaquangfjalskdfj kstn BEgin
begin
(()[]):= <> >= =
1231241
1234567890
```

Kết quả chạy:

```
$ ./main input
Token: tungtaquan
Token: kstn
begin
begin
(
(
)
[
]
)
:=
<>
>=
=
Number: 1231241
So vuot qua 9 chu so!!
```

Tài liệu tham khảo

[1] The Flex Manual Page, Mar 2006. [Online; accessed 25. Oct. 2018].

[2] Lexical Analysis With Flex, for Flex 2.6.2: Top, Oct 2016.

[3] Flex (lexical analyser generator) - Wikipedia, Oct 2018.

[4] IBM Knowledge Center - Using yylex(), Oct 2018.